

# AG2 - Actividad Guiada 2

Nombre: Alberto Paparelli

Link: [https://colab.research.google.com/drive/1csLpxgwXCKv\\_octA0wd5m4v\\_7KIH9biR](https://colab.research.google.com/drive/1csLpxgwXCKv_octA0wd5m4v_7KIH9biR)

Github: [https://github.com/carpe-diem/VIU-03MIAR-algoritmos-de-optimizacion/blob/main/AG2-Actividad-Guiada-2/Algoritmos\\_AG2-Alberto\\_Paparelli.ipynb](https://github.com/carpe-diem/VIU-03MIAR-algoritmos-de-optimizacion/blob/main/AG2-Actividad-Guiada-2/Algoritmos_AG2-Alberto_Paparelli.ipynb)

In [116...]:

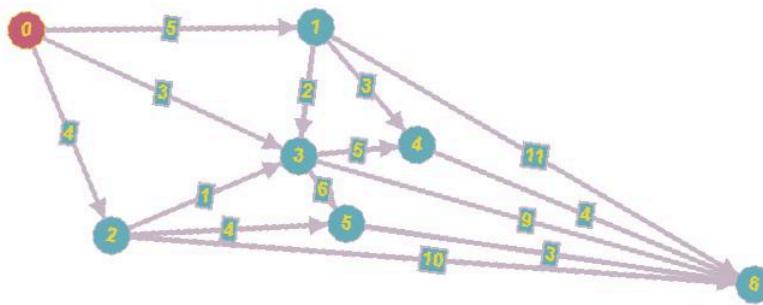
```
import math
```

## Programación Dinámica. Viaje por el río

- **Definición:** Es posible dividir el problema en subproblemas más pequeños, guardando las soluciones para ser utilizadas más adelante.
- **Características** que permiten identificar problemas aplicables:
  - Es posible almacenar soluciones de los subproblemas para ser utilizados más adelante
  - Debe verificar el principio de optimalidad de Bellman: "en una secuencia óptima de decisiones, toda sub-secuencia también es óptima" (\*)
  - La necesidad de guardar la información acerca de las soluciones parciales unido a la recursividad provoca la necesidad de preocuparnos por la complejidad espacial (cuantos recursos de espacio usaremos)

### Problema

En un río hay  $n$  embarcaderos y debemos desplazarnos río abajo desde un embarcadero a otro. Cada embarcadero tiene precios diferentes para ir de un embarcadero a otro situado más abajo. Para ir del embarcadero  $i$  al  $j$ , puede ocurrir que sea más barato hacer un trasbordo por un embarcadero intermedio  $k$ . El problema consiste en determinar la combinación más barata.



- Consideraremos una tabla TARIFAS( $i,j$ ) para almacenar todos los precios que nos ofrecen los embarcaderos.
- Si no es posible ir desde  $i$  a  $j$  daremos un valor alto para garantizar que ese trayecto no se va a elegir en la ruta óptima(modelado habitual para restricciones)

In [117...]:

```
#Viaje por el rio - Programación dinámica
#####
TARIFAS = [
[0, 5, 4, 3, inf, 999, 999], #desde nodo 0
[999, 0, 999, 2, 3, 999, 11], #desde nodo 1
[999, 999, 0, 1, 999, 4, 10], #desde nodo 2
[999, 999, 999, 0, 5, 6, 9],
[999, 999, 999, 0, 999, 4],
[999, 999, 999, 999, 0, 3],
[999, 999, 999, 999, 999, 0]
]

#999 se puede sustituir por float("inf") del modulo math
TARIFAS
```

Out[117...]:

```
[[0, 5, 4, 3, inf, 999, 999],
 [999, 0, 999, 2, 3, 999, 11],
 [999, 999, 0, 1, 999, 4, 10],
 [999, 999, 999, 0, 5, 6, 9],
 [999, 999, 999, 0, 999, 4],
 [999, 999, 999, 999, 0, 3],
 [999, 999, 999, 999, 999, 0]]
```

In [118...]:

```
#Calculo de la matriz de PRECIOS y RUTAS
# PRECIOS - contiene la matriz del mejor precio para ir de un nodo a otro
# RUTAS - contiene los nodos intermedios para ir de un nodo a otro
#####
def Precios(TARIFAS):
##### Total de Nodos
N = len(TARIFAS[0])

#Inicialización de la tabla de precios
PRECIOS = [ [9999]*N for i in [9999]*N] #n x n
RUTA = [ ["]*N for i in [""]*N]

#Se recorren todos los nodos con dos bucles(origen - destino)
# para ir construyendo la matriz de PRECIOS
for i in range(N-1):
    for j in range(i+1, N):
        MIN = TARIFAS[i][j]
        RUTA[i][j] = i
        PRECIOS[i][j] = MIN

        for k in range(i, j):
            if PRECIOS[i][k] + TARIFAS[k][j] < MIN:
                MIN = min(MIN, PRECIOS[i][k] + TARIFAS[k][j] )
                RUTA[i][j] = k
                PRECIOS[i][j] = MIN
```

```
return PRECIOS,RUTA
```

```
In [119... PRECIOS,RUTA = Precios(TARIFAS)
#print(PRECIO[0][6])
```

```
print("PRECIOS")
for i in range(len(TARIFAS)):
    print(PRECIO[i])

print("\nRUTA")
for i in range(len(TARIFAS)):
    print(RUTA[i])
```

```
PRECIOS
[9999, 5, 4, 3, 8, 8, 11]
[9999, 9999, 999, 2, 3, 8, 7]
[9999, 9999, 9999, 1, 6, 4, 7]
[9999, 9999, 9999, 9999, 5, 6, 9]
[9999, 9999, 9999, 9999, 9999, 999, 4]
[9999, 9999, 9999, 9999, 9999, 9999, 3]
[9999, 9999, 9999, 9999, 9999, 9999]
```

```
RUTA
[[], 0, 0, 0, 1, 2, 5]
[[], [], 1, 1, 1, 3, 4]
[[], [], [], 2, 3, 2, 5]
[[], [], [], [], 3, 3, 3]
[[], [], [], [], [], 4, 4]
[[], [], [], [], [], [], 5]
[[], [], [], [], [], [], []]
```

```
In [120... #Calculo de la ruta usando la matriz RUTA
```

```
def calcular_ruta(RUTA, desde, hasta):
    if desde == RUTA[desde][hasta]:
        #if desde == hasta:
        #print("Ir a :" + str(desde))
        return desde
    else:
        return str(calcular_ruta(RUTA, desde, RUTA[desde][hasta])) + ',' + str(RUTA[desde][hasta])

print("\nLa ruta es:")
calcular_ruta(RUTA, 0,6)
```

```
La ruta es:
```

```
Out[120... '0,2,5'
```

## Problema de Asignacion de tarea

```
In [121... #Asignacion de tareas - Ramificación y Poda
```

```
#####
# T A R E A
# A
# G
# E
# N
# T
# E

COSTES=[[11,12,18,40],
        [14,15,13,22],
        [11,17,19,23],
        [17,14,20,28]]
```

```
In [122... # Calculo del valor de una solucion parcial
```

```
def valor(S, COSTES):
    VALOR = 0
    for i in range(len(S)):
        VALOR += COSTES[S[i]][i]
    return VALOR
```

```
valor((3,2, ), COSTES)
```

```
Out[122... 34
```

```
In [123... # Coste inferior para soluciones parciales
# (1,3,) Se asigna la tarea 1 al agente 0 y la tarea 3 al agente 1
```

```
def CI(S,COSTES):
    VALOR = 0
    #Valores establecidos
    for i in range(len(S)):
        VALOR += COSTES[i][S[i]]

    #Estimacion
    for i in range( len(S), len(COSTES) ):
        VALOR += min( [ COSTES[j][i] for j in range(len(S), len(COSTES)) ] )
    return VALOR

def CS(S,COSTES):
    VALOR = 0
    #Valores establecidos
    for i in range(len(S)):
        VALOR += COSTES[i][S[i]]

    #Estimacion
    for i in range( len(S), len(COSTES) ):
        VALOR += max( [ COSTES[j][i] for j in range(len(S), len(COSTES)) ] )
    return VALOR

CI((0,1),COSTES)
```

```
Out[123... 68
```

```
In [124... #Genera tantos hijos como como posibilidades haya para la siguiente elemento de la tupla
#(0,) -> (0,1), (0,2), (0,3)
def crear_hijos(NODO, N):
    HIJOS = []
    for i in range(N):
        if i not in NODO:
            HIJOS.append({'s':NODO +(i,)})
    return HIJOS

In [125... crear_hijos((0,) , 4)

Out[125... [{'s': (0, 1)}, {'s': (0, 2)}, {'s': (0, 3)}]

In [126... def ramificacion_y_poda(COSTES):
#Construccion iterativa de soluciones(arbol). En cada etapa asignamos un agente(ramas).
#Nodos del grafo { s:(1,2),CI:3,CS:5 }
#print(COSTES)
DIMENSION = len(COSTES)
MEJOR_SOLUCION=tuple( i for i in range(len(COSTES)) )
CotaSup = valor(MEJOR_SOLUCION,COSTES)
#print("Cota Superior:", CotaSup)

NODOS=[]
NODOS.append({'s':(), 'ci':CI(),COSTES} )

iteracion = 0

while( len(NODOS) > 0):
    iteracion +=1

    nodo_prometedor = [ min(NODOS, key=lambda x:x['ci']) ][0]['s']
    #print("Nodo prometedor:", nodo_prometedor)

    #Ramificacion
    #Se generan los hijos
    HIJOS =[ {'s':x['s'], 'ci':CI(x['s']), COSTES} for x in crear_hijos(nodo_prometedor, DIMENSION) ]

    #Revisamos la cota superior y nos quedamos con la mejor solucion si llegamos a una solucion final
    NODO_FINAL = [x for x in HIJOS if len(x['s']) == DIMENSION ]
    if len(NODO_FINAL) >0:
        #print("\n*****Soluciones: ", [x for x in HIJOS if len(x['s']) == DIMENSION ] )
        if NODO_FINAL[0]['ci'] < CotaSup:
            CotaSup = NODO_FINAL[0]['ci']
            MEJOR_SOLUCION = NODO_FINAL

    #Poda
    HIJOS = [x for x in HIJOS if x['ci'] < CotaSup ]

    #Añadimos los hijos
    NODOS.extend(HIJOS)

    #Eliminamos el nodo ramificado
    NODOS = [ x for x in NODOS if x['s'] != nodo_prometedor ]

print("La solucion final es:", MEJOR_SOLUCION , " en " , iteracion , " iteraciones" , " para dimension: " ,DIMENSION )
```

ramificacion\_y\_poda(COSTES)

La solucion final es: {'s': (1, 2, 0, 3), 'ci': 64} en 10 iteraciones para dimension: 4

## Descenso del gradiente

```
In [127... import math           #Funciones matematicas
import matplotlib.pyplot as plt #Generacion de graficos (otra opcion seaborn)
import numpy as np              #Tratamiento matriz N-dimensionalas y otras (fundamental!)
# import scipy as sc

import random
```

Vamos a buscar el minimo de la funcion paraboloide :

$$f(x) = x^2 + y^2$$

Obviamente se encuentra en (x,y)=(0,0) pero probaremos como llegamos a él a travéz del descenso del gradiente.

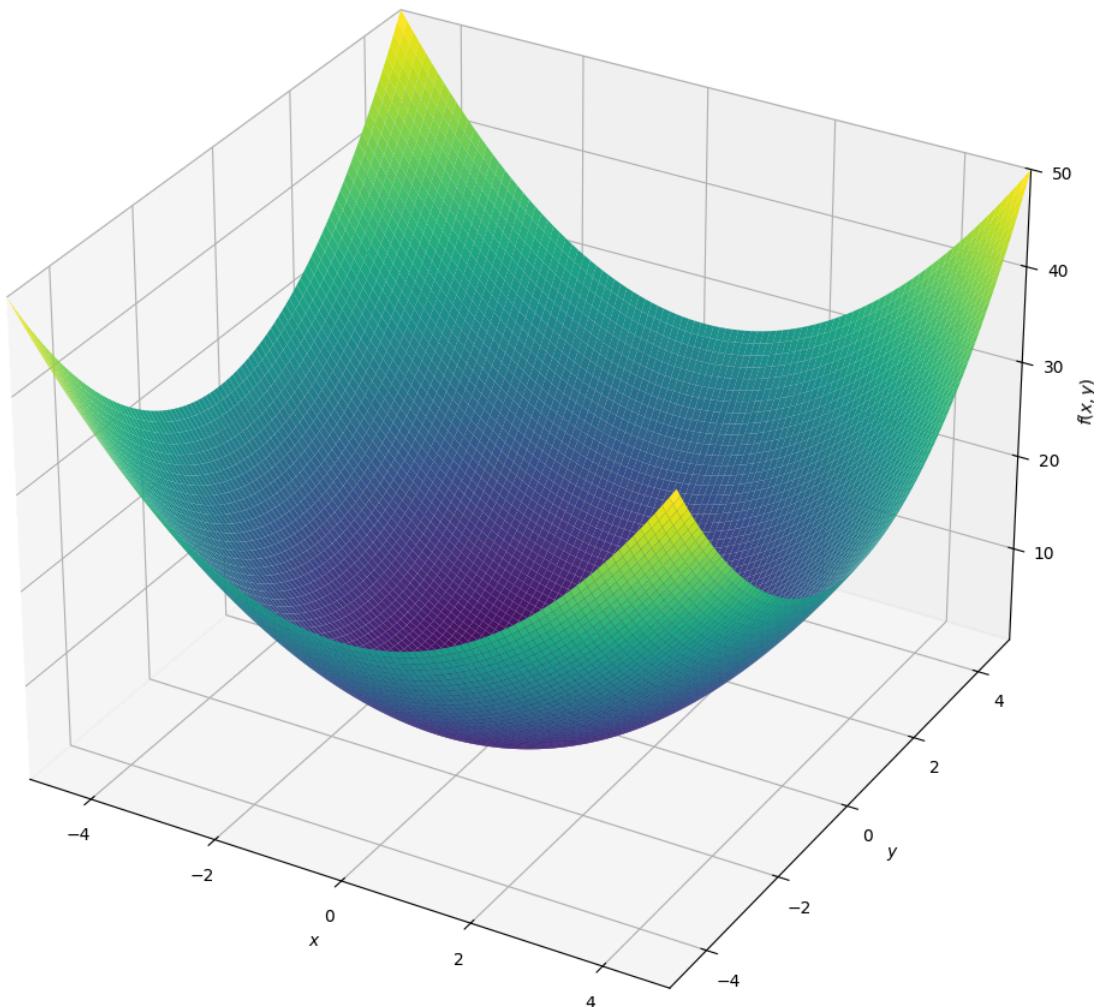
```
In [128... #Definimos la funcion
#Paraboloid
f = lambda X: X[0]**2 + X[1]**2      #Funcion
df = lambda X: [2*X[0] , 2*X[1]]       #Gradiente

df([1,2])
```

Out[128... [2, 4]

```
In [129... from sympy import symbols
from sympy.plotting import plot
from sympy.plotting import plot3d
x,y = symbols('x y')
plot3d(x**2 + y**2,
       (x,-5,5),(y,-5,5),
       title='x**2 + y**2',
       size=(10,10))
```

$$x^{**2} + y^{**2}$$



Out[129]: <sympy.plotting.backends.matplotlibbackend.matplotlib.MatplotlibBackend at 0x114da5820>

In [130]:

```

import time

#Prepara los datos para dibujar mapa de niveles de Z
resolucion = 100
rango=5.5

X=np.linspace(-rango,rango,resolucion)
Y=np.linspace(-rango,rango,resolucion)
Z=np.zeros((resolucion,resolucion))
for ix,x in enumerate(X):
    for iy,y in enumerate(Y):
        Z[iy,ix] = f([x,y])

#Pinta el mapa de niveles de Z
plt.contourf(X,Y,Z,resolucion)
plt.colorbar()

#Generamos un punto aleatorio inicial y pintamos de blanco
random.seed(42)
P=[random.uniform(-5,5),random.uniform(-5,5)]
plt.plot(P[0],P[1],"o",c="white")

#Tasa de aprendizaje. Fija. Sería más efectivo reducirlo a medida que nos acercamos.
TA=.1

#Iteraciones:50
t0 = time.perf_counter()

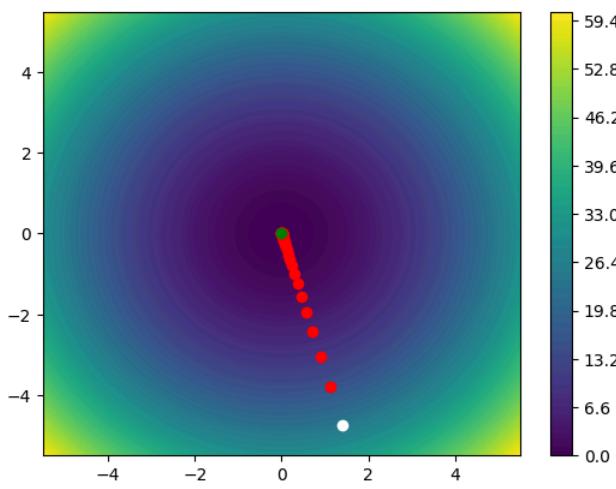
for _ in range(50):
    grad = df(P)
    #print(P,grad)
    P[0],P[1] = P[0] - TA*grad[0] , P[1] - TA*grad[1]
    plt.plot(P[0],P[1],"o",c="red")

t1 = time.perf_counter()

#Dibujamos el punto final y pintamos de verde
plt.plot(P[0],P[1],"o",c="green")
plt.show()
print("Solucion: ", P , f(P))
print(f"Tiempo: {t1-t0:.6f} s | Iteraciones: 50 (fijas)")



```



Solucion: [1.989965764003934e-05, -6.77927303668595e-05] 4.99185066478449e-09  
Tiempo: 0.006834 s | Iteraciones: 50 (fijas)

### Mejora: Parada temprana por convergencia

El descenso del gradiente original ejecuta siempre 50 iteraciones, sin importar si ya encontro el minimo.

**Mejora:** Agregar un criterio de parada basado en la **norma del gradiente**. Cuando  $\|\text{grad } f\| < \text{epsilon}$ , el gradiente es tan pequeño que estamos prácticamente en un mínimo y no tiene sentido seguir iterando.

- `epsilon = 1e-3` : tolerancia de convergencia
- `max_iter = 500` : cota de seguridad
- Misma semilla aleatoria (`random.seed(42)`) que el original para comparacion justa

```
In [131]: import time

# Misma configuracion que el original
resolucion = 100
rango = 5.5

X = np.linspace(-rango, rango, resolucion)
Y = np.linspace(-rango, rango, resolucion)
Z = np.zeros((resolucion, resolucion))
for ix, x in enumerate(X):
    for iy, y in enumerate(Y):
        Z[iy, ix] = f([x, y])

plt.contourf(X, Y, Z, resolucion)
plt.colorbar()

# Mismo punto inicial que el original
random.seed(42)
P = [random.uniform(-5, 5), random.uniform(-5, 5)]
plt.plot(P[0], P[1], "o", c="white")

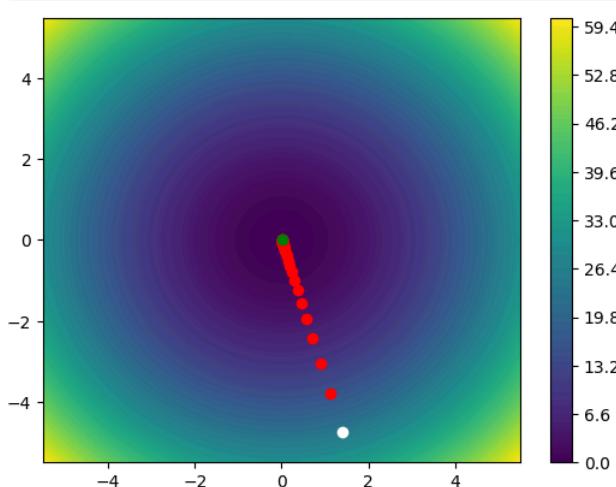
TA = .1
epsilon = 1e-3      # Tolerancia: parar cuando el gradiente sea suficientemente pequeno
max_iter = 500      # Cota de seguridad

t0 = time.perf_counter()

iteraciones_realizadas = 0
for i in range(max_iter):
    grad = df(P)
    grad_norm = math.sqrt(grad[0]**2 + grad[1]**2)
    if grad_norm < epsilon:
        break
    P[0], P[1] = P[0] - TA * grad[0], P[1] - TA * grad[1]
    plt.plot(P[0], P[1], "o", c="red")
    iteraciones_realizadas = i + 1

t1 = time.perf_counter()

plt.plot(P[0], P[1], "o", c="green")
plt.show()
print("Solucion:", P, f(P))
print(f"Tiempo: {t1-t0:.6f} s | Iteraciones: {iteraciones_realizadas} de {max_iter}")
print(f"Norma del gradiente final: {grad_norm:.2e}")
```



Solucion: [0.00011861120247864333, -0.0004040761611870497] 1.773461613930923e-07  
Tiempo: 0.004652 s | Iteraciones: 42 de 500  
Norma del gradiente final: 8.42e-04

## Conclusion

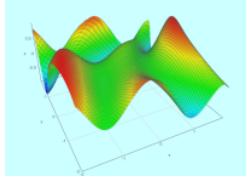
Con la misma semilla (`random.seed(42)`) y el mismo punto inicial, la versión mejorada converge en aproximadamente **42 iteraciones** en lugar de las 50 fijas del original.

La mejora en tiempo puede no ser muy notable porque:

1. El problema es muy sencillo, por lo que cada iteración es muy rápida.
2. La diferencia entre 42 y 50 iteraciones es pequeña en términos absolutos.

¿Te atreves a optimizar la función?:

$$f(x) = \sin(1/2 * x^2 - 1/4 * y^2 + 3) * \cos(2 * x + 1 - e^y)$$



```
In [132]: #Definimos la funcion
f= lambda X: math.sin(1/2 * X[0]**2 - 1/4 * X[1]**2 + 3) *math.cos(2*X[0] + 1 - math.exp(X[1]) )
```